

数字转型 架构演进

SACC

2019 中国系统架构师大会

SYSTEM ARCHITECT CONFERENCE CHINA 2019



2019年10月31-11月2日




北京海淀永泰福朋喜来登酒店



全新IT技术私域交流平台

大规模时间序列分析与根因定位在苏宁的实践

苏宁科技集团云计算研发中心监控云&AIOps研发中心



出品人：汤泳总监

2019/11/02



全新IT技术私域交流平台

个人介绍



汤泳，苏宁科技集团云计算研发中心监控云研发中心总监，AIOps研发中心总监，Band级别: 11。

- 出生年月：1978年08月23日
- 工作经验：15年
- 专业：数学与计算机科学系毕业
- 文化程度：硕士
- 领域：海量数据分析、基于深度学习的时间序列分析与预测、自然语言处理、图模型/图神经网络
- 电话：13813896216
- 邮箱：mark.tang19780823@outlook.com

业务场景

数据

- 基础设施监控
- 实时日志分析
- 端侧监控/调用链



分析

- 流式处理
- 多维数据分析
- 时间序列数据分析



算法

- 时间序列预测
- 异常检测
- 基于图模型的根因分析

主要内容

- 背景介绍
- 大规模时间序列分析
- 根因定位
- 异常检测平台深度剖析
- 未来规划

背景介绍：Operational 预测

参考文献：Tim Januschowski. (2017). Forecasting at Amazon Problems, Methods and Systems

- Example: Demand forecast for retail products
- millions of time series per scientists (machine learning & software development engineers)
- forecast horizon: days, weeks, at most months
- runs at least daily/on-demand
- hands-off approach
- models can be more black box as long as they are robust
- low counts, bursty, short history and life cycles, intermittent

BEEM咖啡机家用全自动 19BAR意式浓缩商用办公室咖啡机 全自动打奶泡一键清洗原装进口 银色CJ-265

【送咖啡杯和豆】【德国进口】可一键制作浓缩咖啡，卡布奇诺，拿铁，单独奶泡按键可热牛奶dry 买就送咖啡礼包，晒图评价联系客服赢好礼！点这里。

易购价 **¥1599.00** 降价通知

累计评价
70+

会员 加入会员返云钻，下单立返约31.98元 [立即开通>](#)

优惠 可参加以下优惠活动

¥200 满1599用200 共1张优惠券>

云钻 刮券 100%刮中券，最高50元无敌券 [立即去刮奖>](#)

赠品 *1 *1 赠完即止


实名有礼 实名认证领苏宁支付券 [登录后查看>](#)

云钻 普通会员返479云钻

送至 北京 东城区 有货 免运费

由 ExzellenzVerdon官方旗舰店 从 宁波市 销售和发货，并提供售后服务 [联系客服](#)

型号 CM-119A 02051 03201 03428200235



背景介绍：智能异常检测

传统检测



智能异常检测



挑战

- ①面对海量运维监控数据，需要快速止损，人工决策时间往往是小时级但人肉监控(例如ELK)不现实，决策时间往往是小时甚至天级别。
- ②对于异常点往往需要丰富的经验去识别，但是随着时间的推移，业务数据的特点会发生变化，从而过去的经验也需要与时俱进的更新。

我们的方法：

- ①AI取代缓慢易错的人力决策部分，快速发现问题并且给出决策建议（分钟级）或提前规避故障。
- ②使用历史数据结合AI算法自动更新业务经验知识。

主要内容

- 背景介绍
- **大规模时间序列分析**
- 根因定位
- 异常检测平台深度剖析
- 未来规划

大规模时间序列分析

传统时间序列预测方法

指数平滑 (ETS) :


$$\hat{z}_{T+h} = \alpha z_T + \alpha(1-\alpha)z_{T-1} + \alpha(1-\alpha)^2 z_{T-2} + \cdots + (1-\alpha)^T \hat{z}_1 \quad \alpha : \text{平滑系数}$$

自回归 (AR) :

$$z_t = \sum_{l=1}^p w_l z_{t-l} + b + \epsilon_t \quad \epsilon_t : \text{高斯噪声} \quad \epsilon_t \sim \mathcal{N}(0, \sigma^2)$$

状态空间模型 (SSM) :

$$z_t = \mathbf{a}_t^T \mathbf{l}_{t-1} + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, \sigma^2)$$
$$\mathbf{l}_t = \mathbf{F}_t \mathbf{l}_{t-1} + \mathbf{g}_t \epsilon_t, \quad \mathbf{l}_0 \sim \mathcal{N}(\boldsymbol{\mu}_0, \text{diag}(\sigma_0^2)).$$



传统时间序列预测方法存在的问题 :

- 针对单个时间序列建模，不能充分利用时间序列之间的相关性
- 每个时间序列需要足够的历史数据进行训练
- 本质上只能捕捉线性关系，而不能捕捉非线性关系
- 无法处理时间序列的冷启动问题

大规模时间序列分析

基于深度学习的大规模时间序列预测方法--DeepAR

算法原理及流程：

$$\ell_{\text{NB}}(z|\mu, \alpha) = \frac{\Gamma(z + \frac{1}{\alpha})}{\Gamma(z + 1)\Gamma(\frac{1}{\alpha})} \left(\frac{1}{1 + \alpha\mu}\right)^{\frac{1}{\alpha}} \left(\frac{\alpha\mu}{1 + \alpha\mu}\right)^z$$

$$\ell_{\text{G}}(z|\mu, \sigma) = (2\pi\sigma^2)^{-\frac{1}{2}} \exp(-(z - \mu)^2/(2\sigma^2))$$

计算loss

网络

Encoder
(LSTM)


Decoder
(LSTM)

输入

- 1、上一时刻的真实值
- 2、当前时刻的特征

- 1、上一时刻的真实值（训练）/预测值（推理）
- 2、当前时刻的特征

预测效果：



Pros

- 对相关的时间序列建立统一的预测模型，适用于海量数据场景
- 可以同时点预测和概率分布预测
- 冷启动预测，实现少量历史数据预测

Cons

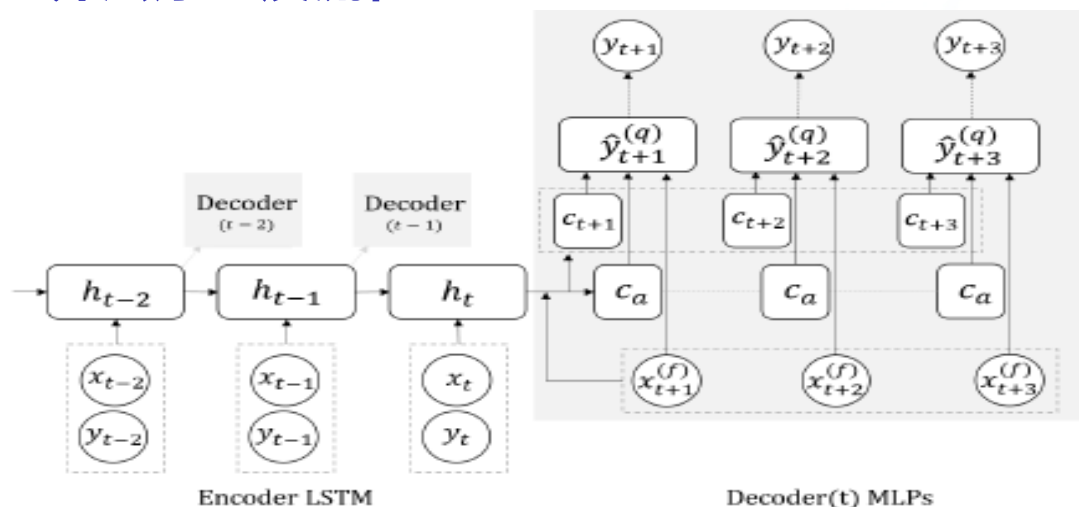
- 没有使用attention机制，LSTM对较长的时间序列可能会出现记忆丢失的问题，无法捕获长周期、季节等信息

参考文献：Flunkert, V., Salinas, D., Gasthaus, J., and Januschowski, T. (2017). Deepar: Probabilistic forecasting with autoregressive recurrent networks. International Journal of Forecasting, arXiv:1704.04110.

大规模时间序列分析

基于深度学习的大规模时间序列预测方法--MQRNN

算法原理及流程：



Global_MLP

$$(c_{t+1}, \dots, c_{t+K}, c_a) = m_G(h_t, x_{t:}^{(f)})$$


Local_MLP

$$(\hat{y}_{t+k}^{(q_1)}, \dots, \hat{y}_{t+k}^{(q_q)}) = m_L(c_{t+k}, c_a, x_{t+k}^{(f)})$$

计算loss

$$L_q(y, \hat{y}) = q(y - \hat{y})_+ + (1 - q)(\hat{y} - y)_+ \\ \sum_t \sum_q \sum_k L_q(y_{t+k}, \hat{y}_{t+k}^{(q)})$$

预测效果：



Fork decoder机制

- (1)MQRNN在训练时，Encoder每一个时间点的输出都进行Decoding，loss基于所有Decoder的输出计算；
- (2)由于采用了分位数回归机制，Decoder每个时间点的输出与前一个时间点的输出无关，消除了累积误差的影响。
- (3)MQRNN输出为分位数矩阵，可以同时得到不同分位数上的预测值。

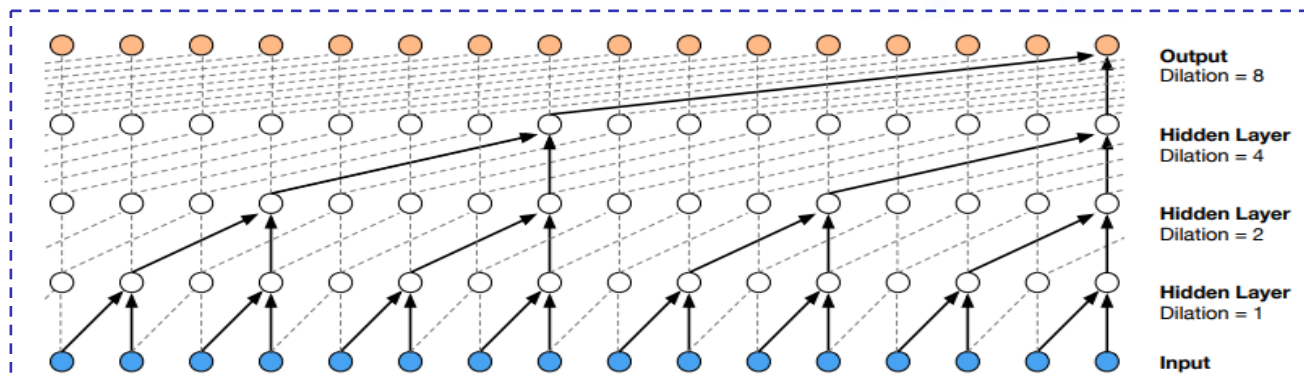
参考文献：Wen, R., Torkkola, K., and Narayanaswamy, B. (2017). A multi-horizon quantile recurrent forecaster. NIPS Workshop on Time Series, arXiv:1711.11053.

大规模时间序列分析

基于深度学习的大规模时间序列预测方法--MQCNN

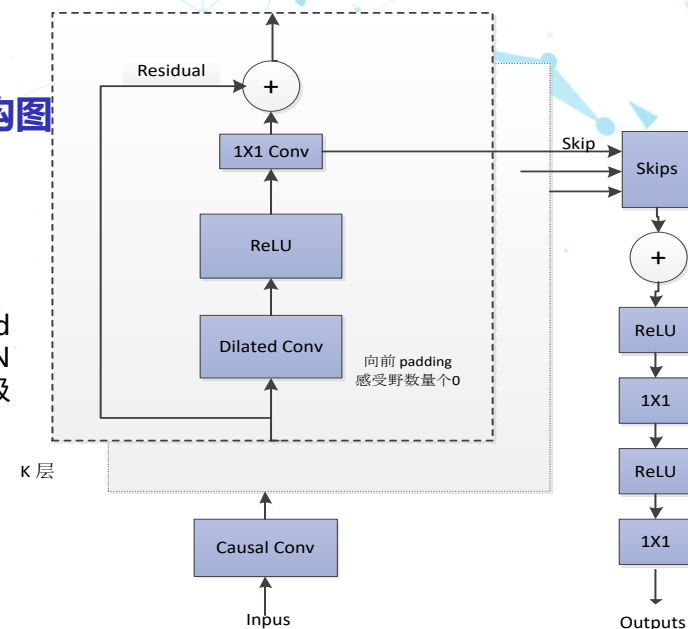
◆ MQCNN的Encoder采用类似Wavenet的膨胀CNN，decoder与MQRNN一致

Encoder部分示意图



Wavenet结构图

使用 Dilated Conv可以使CNN的接收域呈指数级增长

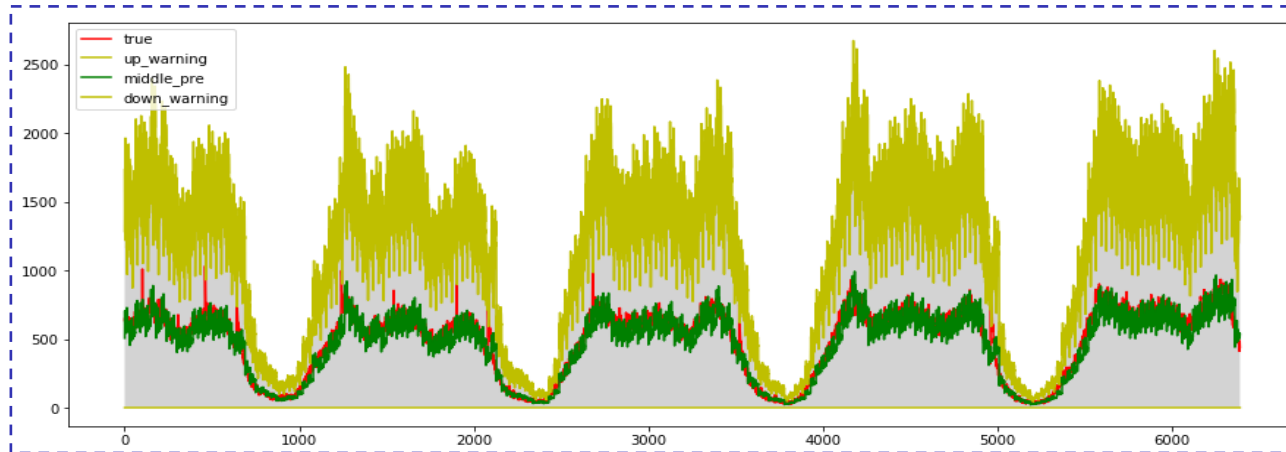


Pros

- MQC的encoder为CNN，训练速度更快
- 通过Dilated Conv能使模型处理更大长度的输入数据

Cons

- 对率型数据预测效果没有计数型好



参考文献：Wen, R., Torkkola, K., and Narayanaswamy, B. (2017). A multi-horizon quantile recurrent forecaster. NIPS Workshop on Time Series, arXiv:1711.11053.

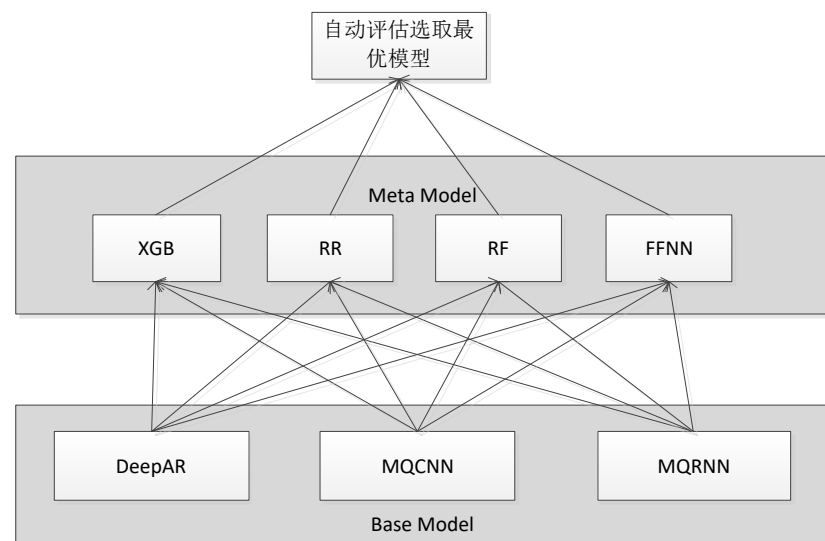
大规模时间序列分析

基于深度学习的大规模时间序列集成预测方法

Count指标	FFNN_ensemble	XGB_ensemble	RF_ensemble	RR_ensemble	SWA_ensemble	deepar	mqrnn	mqcnn
average_rmse	246.5465463	215.2504627	242.4357493	222.3948193	222.6	449.5706847	248.0498881	236.7997323
average_smape	0.23845897	0.168967407	0.17394335	0.183429568	0.2336	0.226921157	0.260262193	0.209053173
Rate指标	FFNN_ensemble	XGB_ensemble	RF_ensemble	RR_ensemble	SWA_ensemble	deepar	mqrnn	mqcnn
average_rmse	0.06104917	0.061365402	0.061787037	0.061437497	0.0835	0.08324926	0.207378284	0.188028418
average_smape	0.05566648	0.055913178	0.057515839	0.056988203	0.0976	0.077240894	0.328145736	0.307668142

集成模型：

- 单个预测模型在不同类型的数据上性能差异较大，DeepAR模型对rate指标预测效果较好，但count指标预测效果较差，MQCNN对count指标预测效果较好，但rate指标预测效果较差
- 集成模型的目标是结合各模型的优势，得到比单个模型更优、更鲁棒的结果。使用FFNN（前馈神经网络）/XGB（xgboost）/RF（随机森林）/RR（岭回归）/简单加权平均（SWA）等作为stacking meta learner，最终根据评估指标自动选择最优集成模型。



大规模时间序列分析

基于深度学习的大规模时间序列集成预测方法

集成算法的设计思路及流程：

- **SWA 方法**比较简单，只要计算出相应的权重。**XGB/RR/RF/FFNN等方法**则相对复杂一点，需要进行如下处理：
- **数据预处理**：对deepar,mqrnn,mqcnn的预测结果进行标准化，使用（预测值-均值）/标准差的方法。实验表明，标准化后的集成效果好于非标准化的数据。
- **模型输入**：deepar,mqrnn,mqcnn的预测结果，时间序列的特征（分钟，小时，星期几等），时间序列的编号等。
- **损失函数**：均方差，并增加L2正则化，防止过拟合。

集成模型自动评估和选择：

- 使用测试数据真实值与集成模型预测值的SMAPE作为评估指标。自动选取测试集上SMAPE值最小的模型作为最终的集成模型。

预测上下边界生成：

- 使用集成模型的预测值及各基模型的标准差作参数，采样选取合适的分位数生成上下边界。

大规模时间序列分析

基于深度学习的大规模时间序列集成预测方法





- 上图为count型数据使用xgboost集成的效果。
下图为rate型数据使用FFNN集成的效果。
- 黑色为真实值；绿色，黄色和红色分别为deepar,mqrnn 和mqcnn的预测值。蓝色为集成后的预测值。
- 集成后的预测值比单个模型的预测值更稳定，更接近真实值。



大规模时间序列分析

基于深度学习的大规模时间序列集成预测方法

- 下图显示的为count类型数据和rate类型数据，根据集成模型预测值，生成上下边界的效果图。
- 其中：黑色为真实值；绿色，黄色和红色分别为deepar,mqrnn和mqcnn的预测上下边界值；蓝色为集成后的预测值；紫色为集成后的上下边界值。
- 由图可知，集成后的预测边界比单个模型的预测边界更稳定，更合理。



主要内容

- 背景介绍
- 大规模时间序列分析
- 根因定位
- 异常检测平台深度剖析
- 未来规划

根因定位

背景

可加性KPI（如登录量、支付成功数等）是业务中的一类重要的指标。当可加性KPI总指标发生异常时，我们希望使用根因定位算法快速定位导致总指标出现异常的根源（例如：南京地区的iOS端的家电品类的支付成功数异常导致了总的支付成功数发生异常）。

一个KPI指标根据多种属性分别监控。比如Page Views（PV），分别统计来自不同ISP和不同省份的PV。如图.1所示：

$f(p,i) \rightarrow v(p,i)$		Province(p)			
		Beijing	Shanghai	Guangdong	*
ISP(i)	Mobile	20→14	15→9	10→10	45→33
	Unicom	10→7	25→15	20→20	55→42
	*	30→21	40→24	30→30	100→75

Fig.1

表中的 f 和 v 分别表示PV的期望的正常值和观测值，我们看到红色的部分观测值和正常值不符，这些PV就是发生了异常。

根因定位问题希望的是定位发生异常时那些属性取值导致了异常，比如Fig.1中的根因就应该是（Province=Beijing&Shanghai, ISP=*）

主要存在以下挑战：

- 不同维度值组合之间不是相互独立的，根因的异常通常会传播到其他维度值组合，导致不同维度值组合异常的纠缠，真正的根因难于甄别
- 要对异常根因进行定位，须对所有维度值组合构成的巨大空间进行搜索。以登录线为例，数据包含4个维度，总的最细粒度维度值组合数量在百万量级，而搜索空间更是百万量级的指数级别($> 2^{1000000}$)。

配图来自：<https://www.zhihu.com/question/331456480/answer/806871325>

根因定位

HotSpot算法核心思想

针对上述难点，我们探索并利用Hotspot算法作为解决方案。该算法的核心思想包括以下三方面：


- ① ripple effect：异常传播模型，用于解决维度值组合之间异常的互相纠缠问题。

$$\frac{v(\text{child}) - f(\text{child})}{f(\text{child})} = \frac{v(\text{parent}) - f(\text{parent})}{f(\text{parent})}$$

- ② potential score：用于评估某维度值组合作为根因的置信程度。

$$ps = \max(1 - \frac{d(\text{real}, \text{deduced})}{d(\text{real}, \text{forecast})}, 0)$$

- ③ 蒙特卡洛树搜索（MCTS）：用于解决在巨大空间中的搜索问题。



参考文献：[1] Y. Sun, Y. Zhao, Y. Su, D. Liu, X. Nie, Y. Meng, S. Cheng, D. Pei, S. Zhang, X. Qu et al., "Hotspot: Anomaly localization for additive kpis with multi-dimensional attributes," IEEE Access, vol. 6, pp. 10 909–10 923, 2018.

根因定位

根因定位整体流程

■ 数据准备

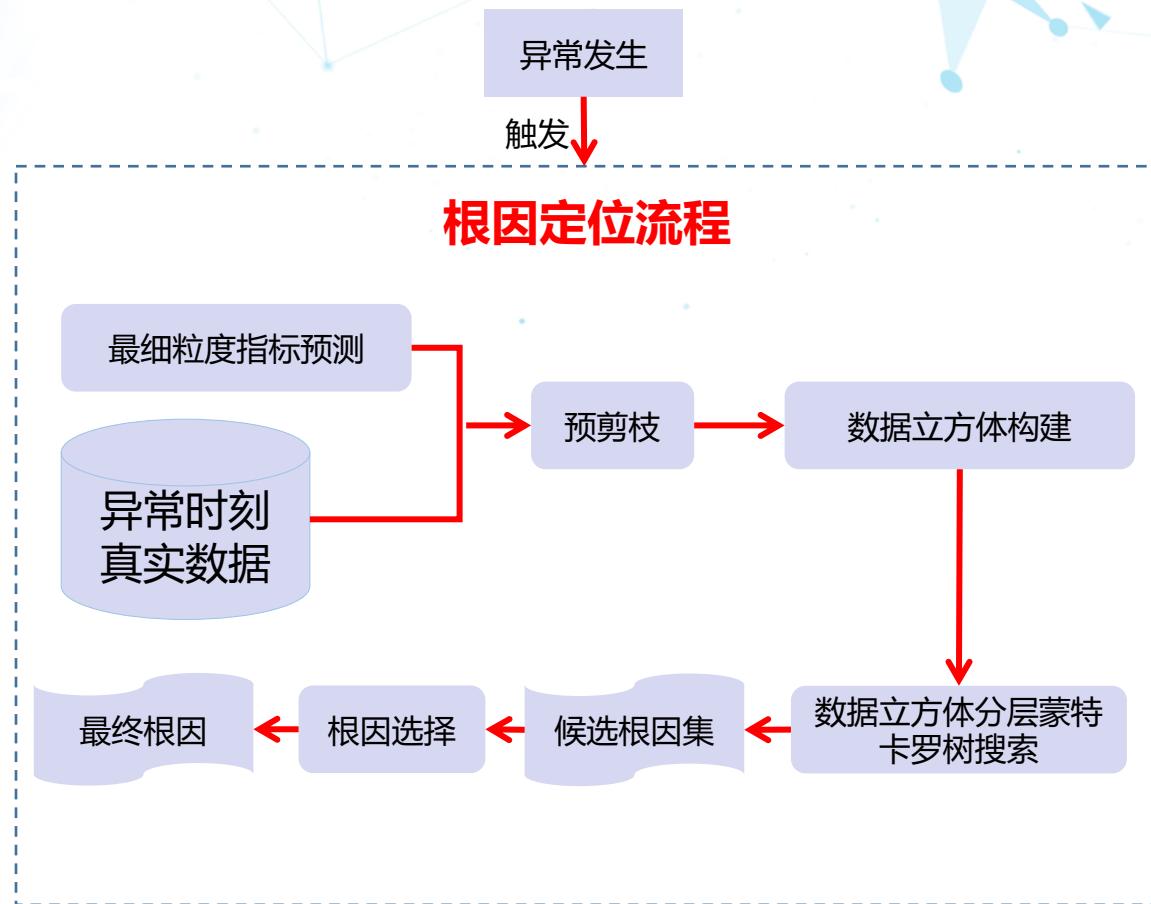
- 1、最细粒度指标预测。
- 2、依据最细粒度指标预测结果进行预剪枝，剔除大量对总指标异常几乎不构成贡献的维度值，形成预剪枝后的维度值集合。
- 3、构建全维度值（预剪枝后的）组合的最细粒度指标预测值和真实值。

■ 层次化蒙特卡洛树搜索

- 1、对最细粒度指标的预测值和真实值构建所有视角下的数据立方体（cuboid），例如cuboid_city、cuboid_loginType是单维度cuboid、cuboid_city_loginType是一个2维度cuboid，以此类推。
- 2、依据数据立方体的维度数量对cuboid进行分层，单维度cuboid为第一层，全维度cuboid在最底层。
- 3、自上而下分别对每一层的每一个cuboid进行搜索。利用上层搜索结果对下层进行剪枝后，再进行下层的搜索。搜索过程层间串行，层内并行。
- 4、每一个cuboid的搜索结果是一个根因元素集，作为最终根因集的候选集。

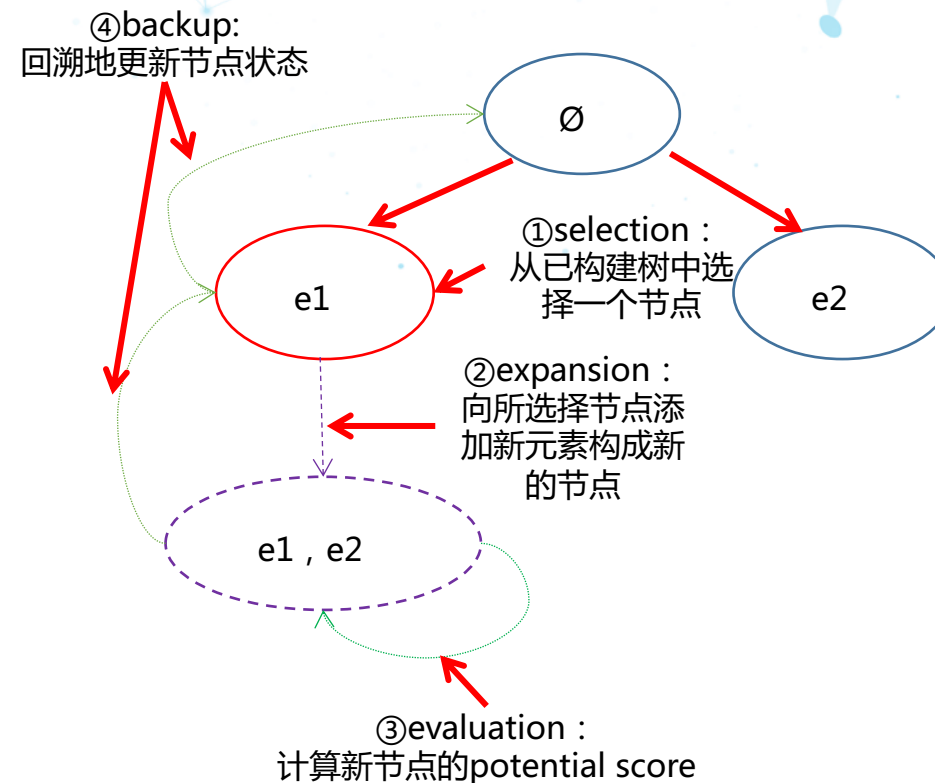
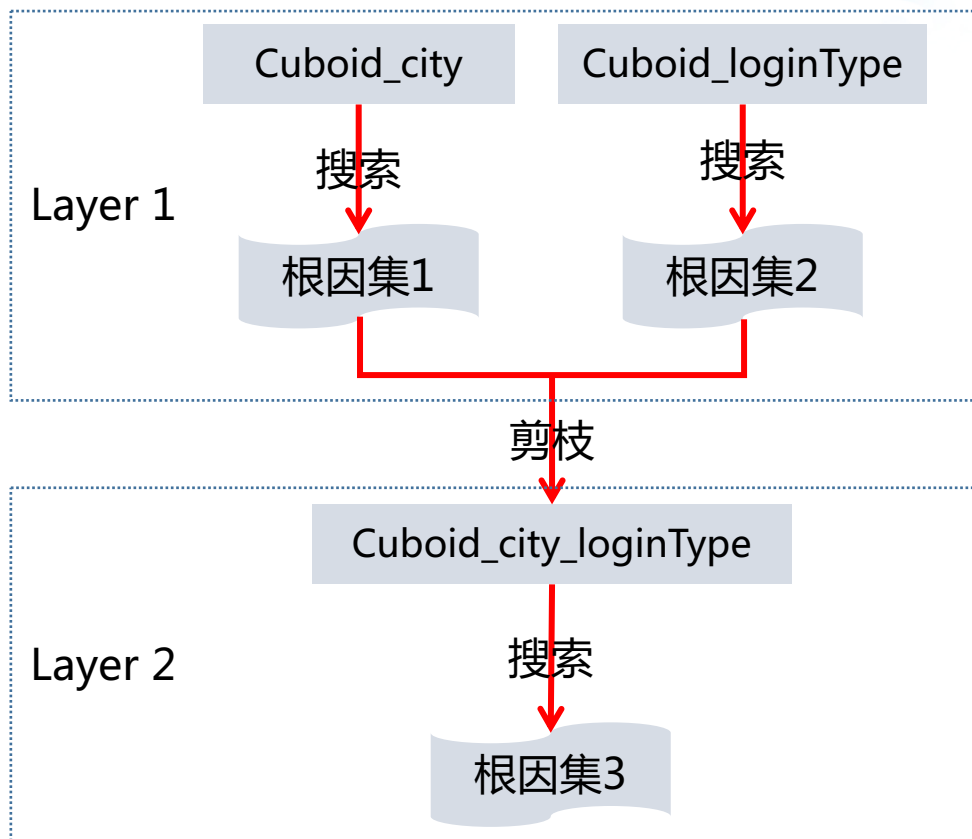
■ 根因确认

- 1、从所有cuboid的搜索结果中选择potential score最大的候选根因集作为最终根因集。
- 2、如遇两个cuboid的候选根因集的potential score接近，根据奥卡姆剃刀原理选择最简者。



蒙特卡洛树搜索 (MCTS)

cuboid内部MCTS搜索策略



根因定位


Hotspot应用案例

某日凌晨02:26，登录成功量发生异常陡增。

Hotspot将根因定位到：{地区: 内网IP, 会员角色: 142000000154, 类型: SuningUsernamePasswordAuthenticationHandler}。


如下图，后期分析结果验证了根因定位结果的准确性。左图为发生异常的总指标，右图为定位结果分解后的3个单维度指标。

登录成功数 异常




内网IP地区登录成功数 异常

本期均值：2196.05 对比期均值：39.74 对比期增长率：




SuningUsernamePasswordAuthenticationHandler类型登录成功数 异常

本期均值：2279.79 对比期均值：77.27 对比期增长率：



142000000154会员角色登录成功数 异常

本期均值：4471.51 对比期均值：2195.47 对比期增长率：



Hotspot算法的演化

HotSpot存在的问题：

- ①只能对基础可加性指标进行根因定位，不能直接处理复合指标，如成功率等。
- ②容易忽略变化幅度较小的异常。
- ③定位深层cuboid根因和由多个元素构成的根因时，准确率下降。
- ④计算量较大，算法运行时间较长。

考虑到HotSpot存在的问题，Squeeze[1]算法进行改进，Squeeze的主要优势是：

- ①提出泛化的ripple effect (GRE)，可以直接处理由可加性指标复合得到的指标，如成功率等。
- ②改进的potential score (GPS) 对变化幅度较小的异常也较为敏感，不易忽略此类异常。
- ③当根因所在层次较深或者根因集包含多个元素时，准确率不发生明显下降。
- ④不需要构建全量数据，计算量较小，算法运行时间相对稳定。

参考文献：[1] Zeyan Li, Chengyang Luo, Yiwei Zhao, Yongqian Sun et al. "Generic and Robust Localization of Multi-Dimensional Root Causes", ISSRE 2019, Berlin, Germany, Oct 28-31, 2019

根因定位

Squeeze算法基本原理

Squeeze算法分为两个主要的环节：通过Bottom-Up Searching缩小搜索空间、通过Top-Down Localization进行根因定位。

■ Bottom-Up Searching

①deviation based filtering：通过寻找绝对偏差的累积概率分布的膝点对叶子元素进行过滤，过滤掉大部分正常叶子元素。

②deviation score based clustering：基于相对偏差，对经过filtering得到的异常叶子元素进行分组，每组代表一个异常簇。

■ Top-Down Localization

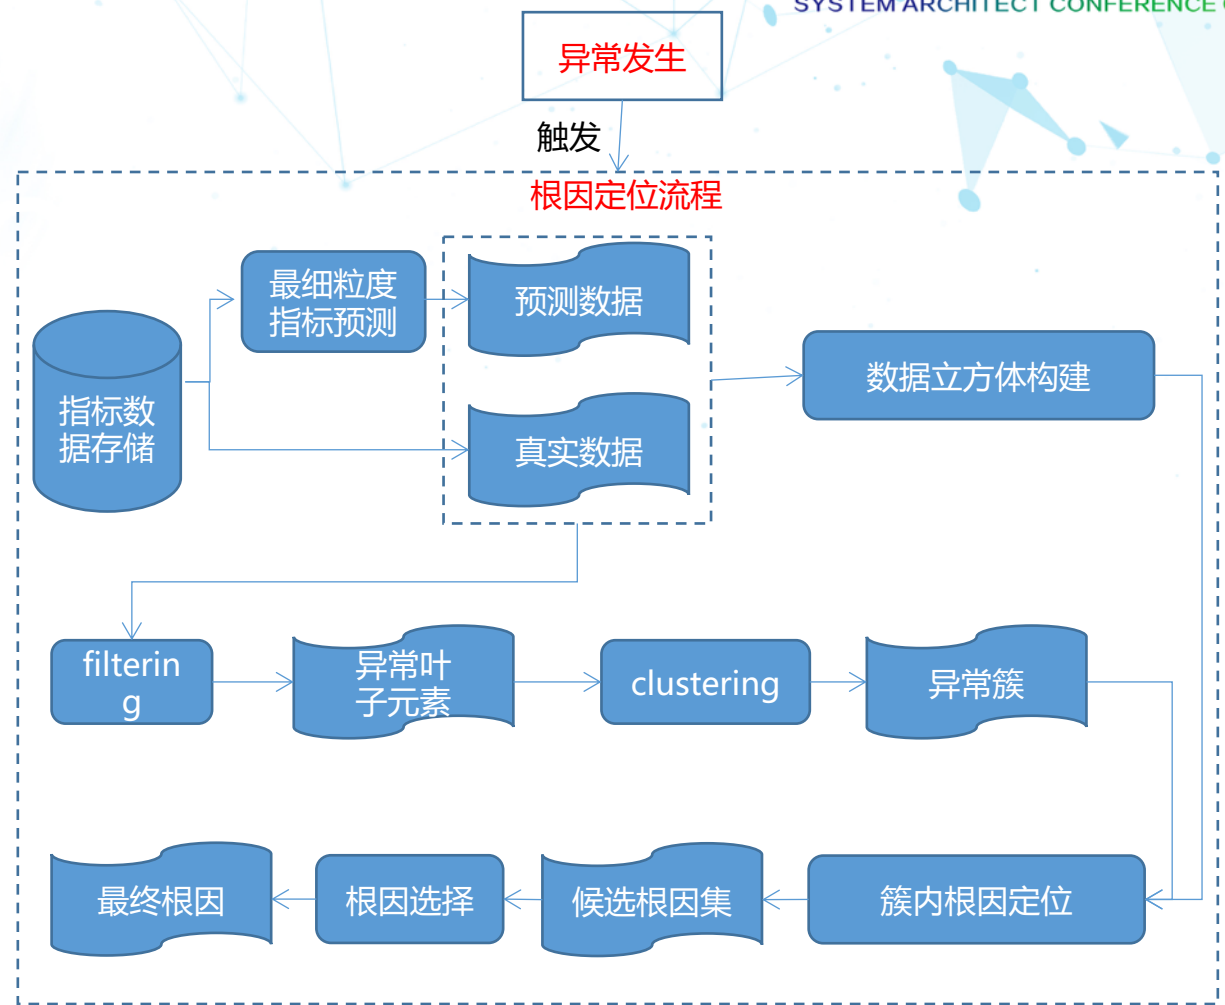
对每一个异常簇，进行簇内的根因定位，输出导致该异常簇的根因集。

簇内根因定位的基本思想是：

①层次化搜索策略：对预先构建的数据立方体（cuboid）进行层次化的搜索，如果上层cuboid搜索结果满足终止条件，即终止搜索。

②cuboid内搜索策略：以descent score作为优先搜索策略，以泛化的potential score（GPS）作为评价指标，定位最大GPS的元素集作为该cuboid的候选根因集。

③根因确认：针对所有cuboid的候选根因集，依据奥卡姆剃刀原理，对候选根因集的GPS和简洁性进行平衡，选择最终根因。



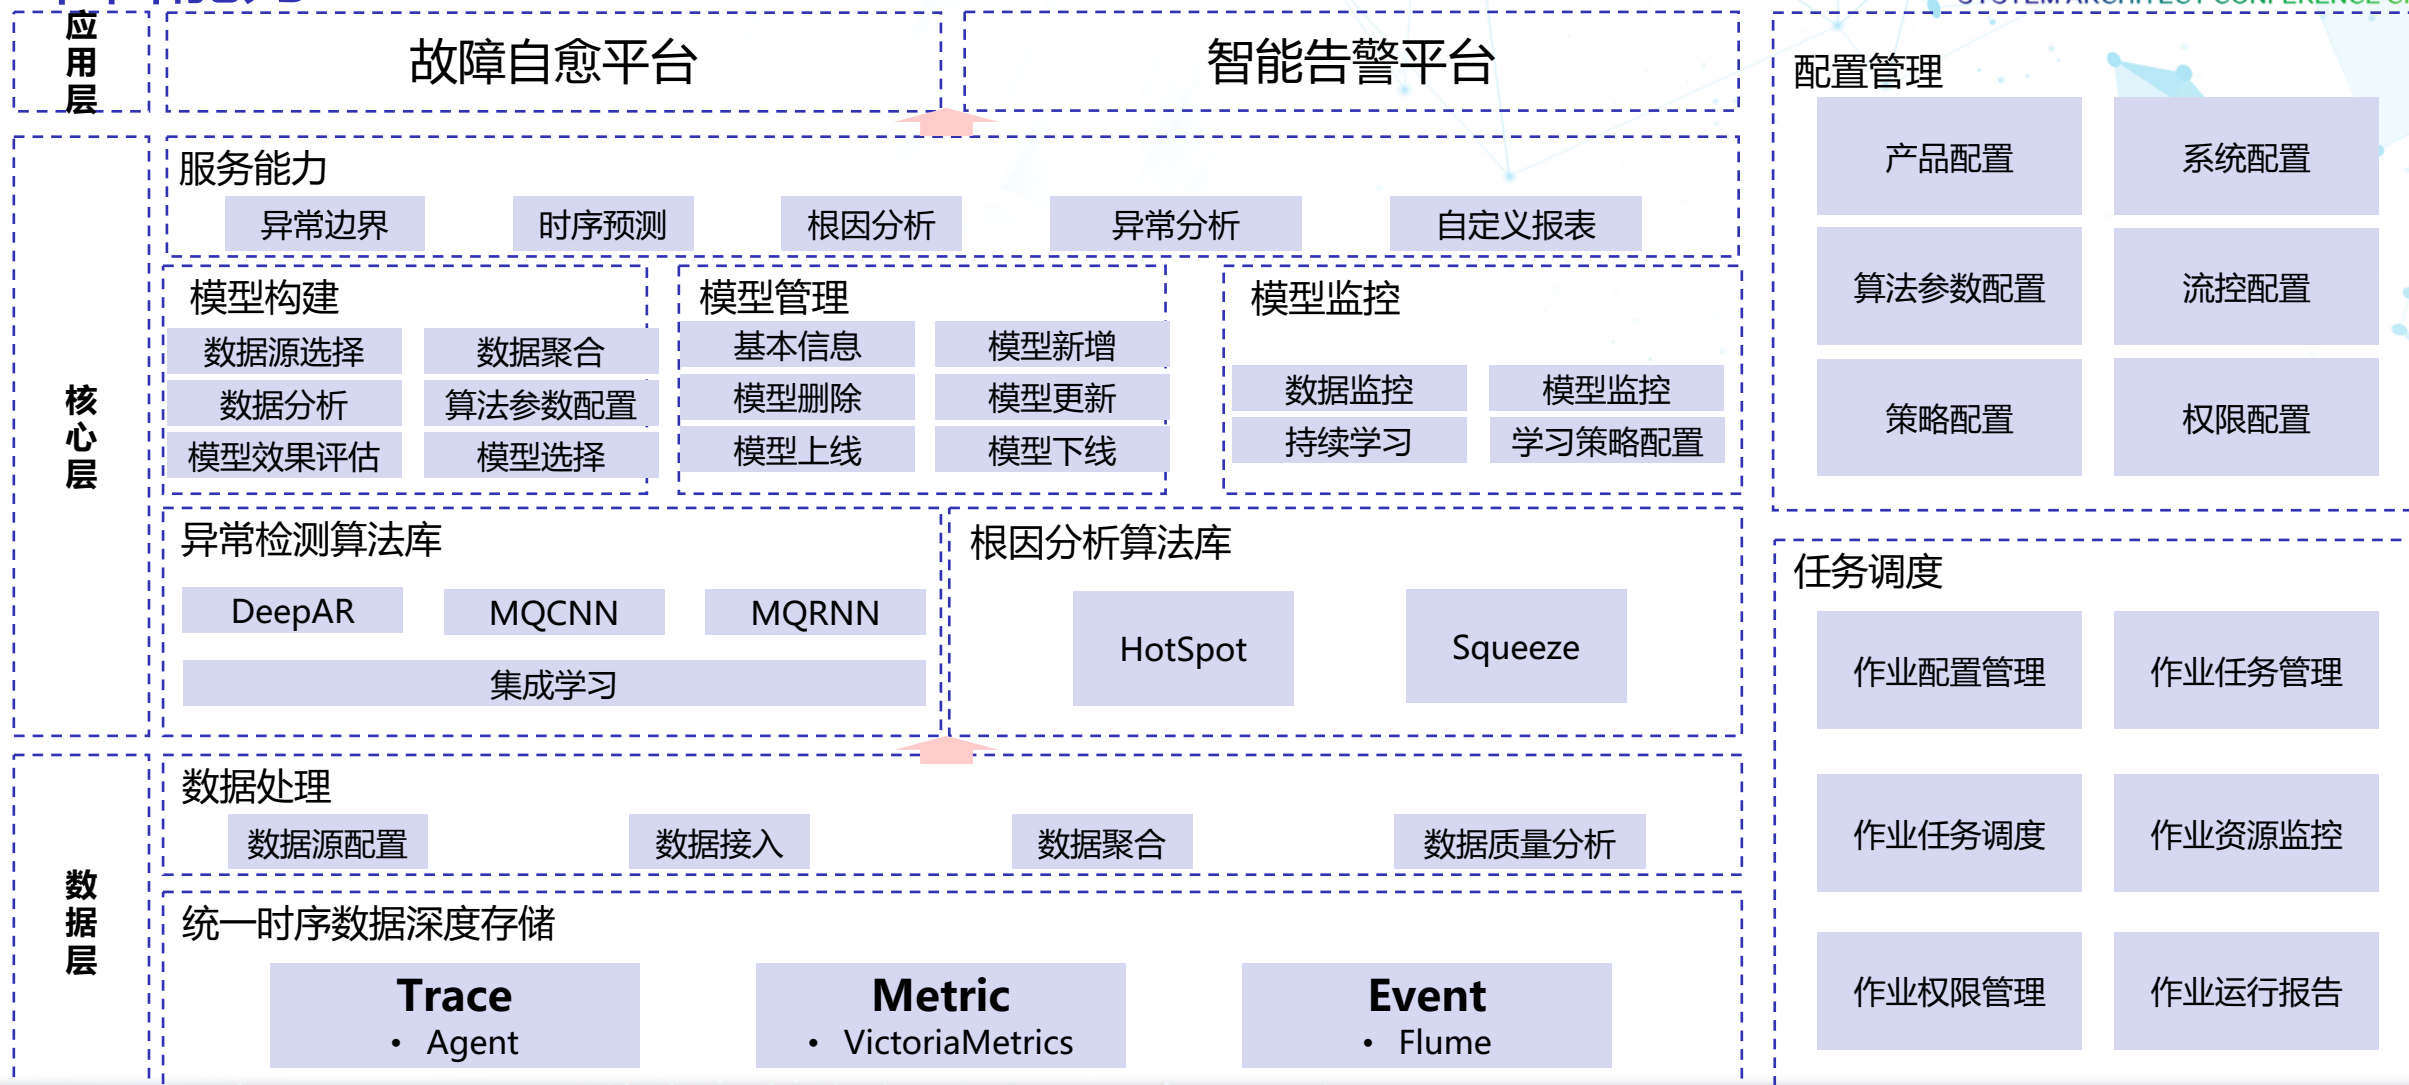
参考文献：[1] Zeyan Li, Chengyang Luo, Yiwei Zhao, Yongqian Sun et al. "Generic and Robust Localization of Multi-Dimensional Root Causes", ISSRE 2019, Berlin, Germany, Oct 28-31, 2019

主要内容

- 背景介绍
- 大规模时间序列分析
- 根因定位
- **异常检测平台深度剖析**
- 未来规划

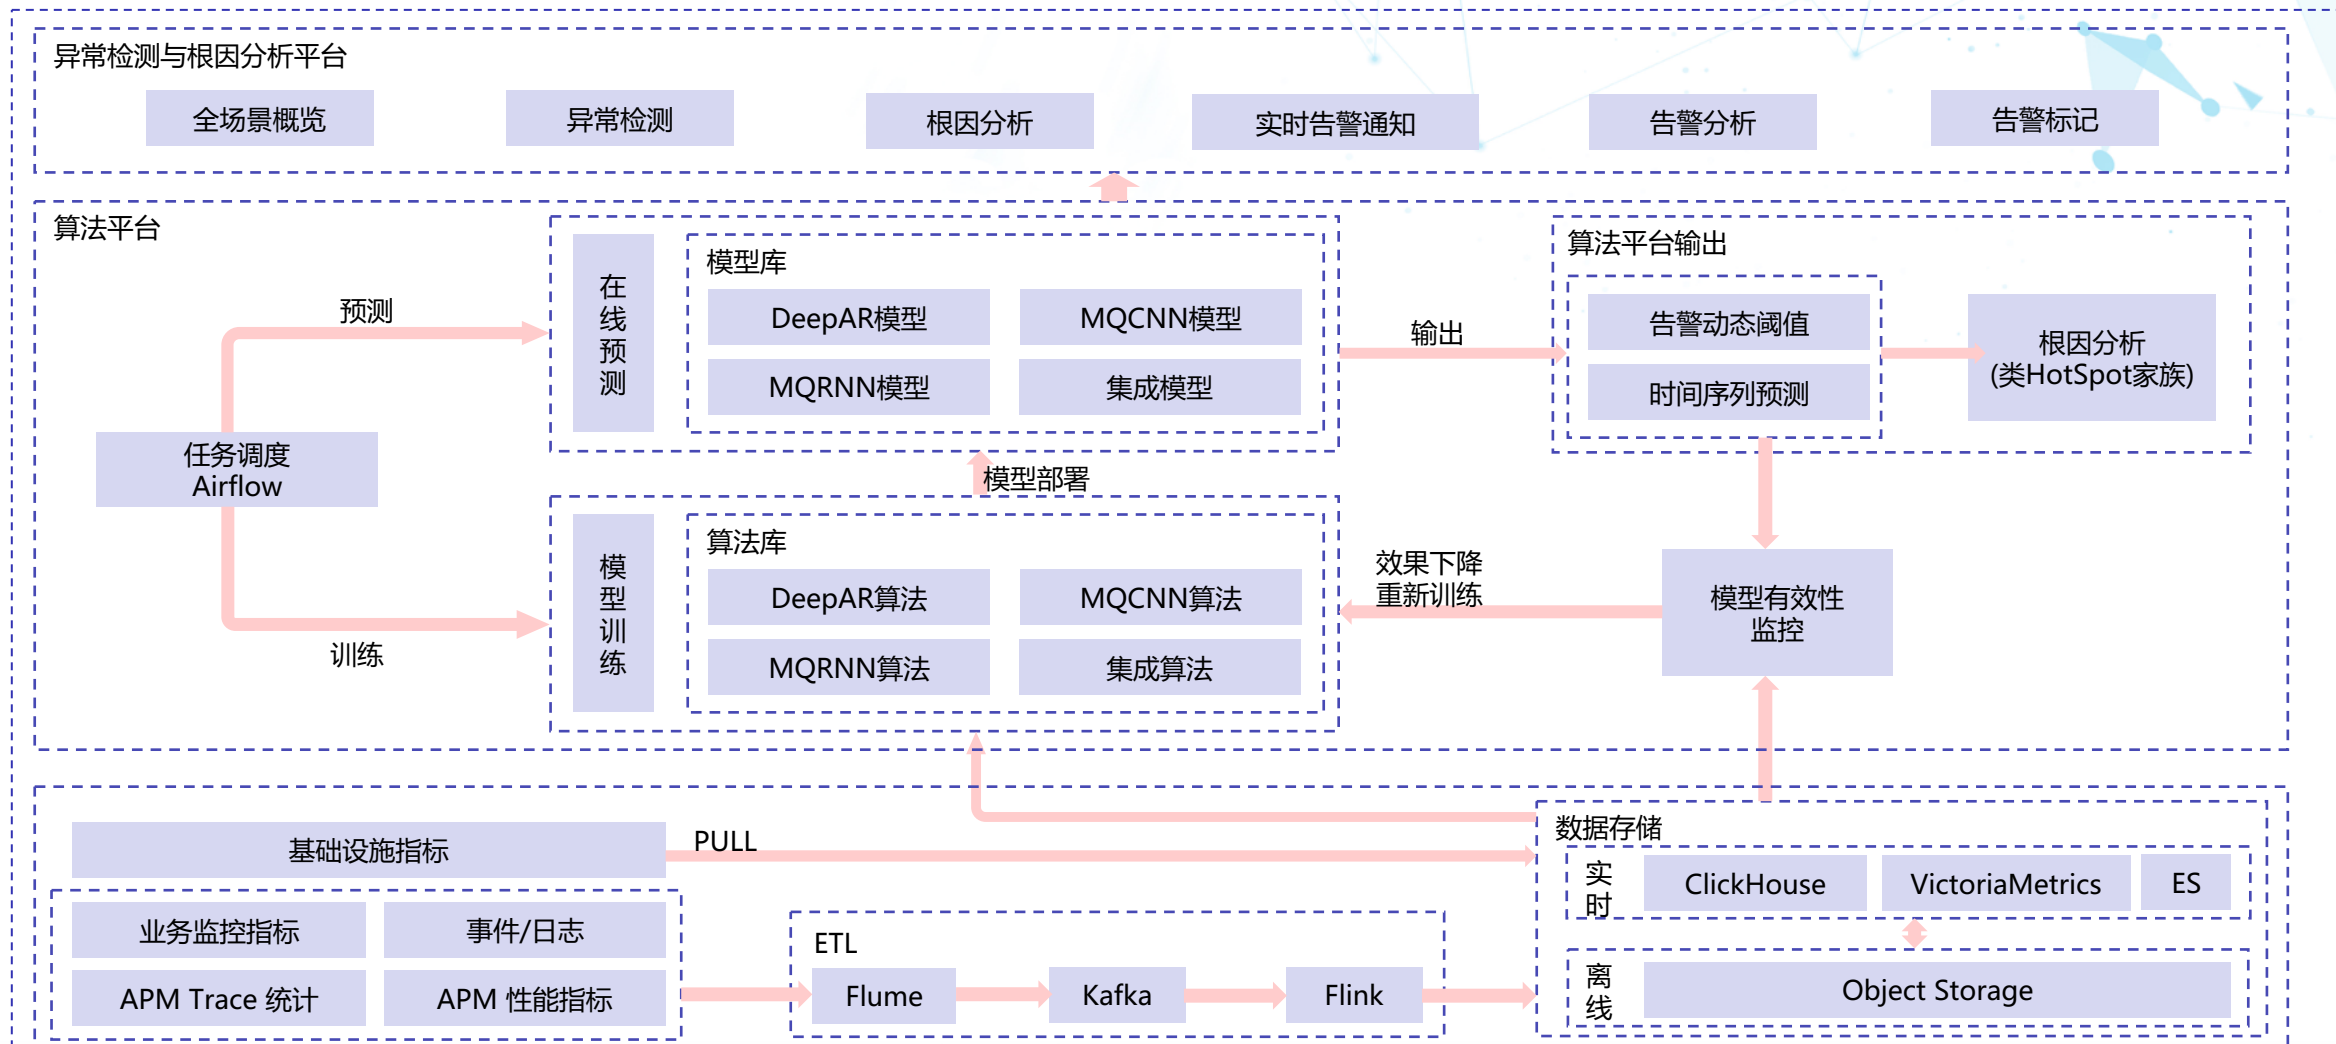
异常检测平台深度剖析

平台能力



异常检测平台深度剖析

平台技术架构



异常检测平台深度剖析

数据源接入

数据接入

实时消息接入

实时文件接入

数据实时聚合

数据存储

实时批量写

实时聚合

数据离线备份

分布式存储

数据统计备份

系统信息存储

数据分析报告

数据量趋势分析

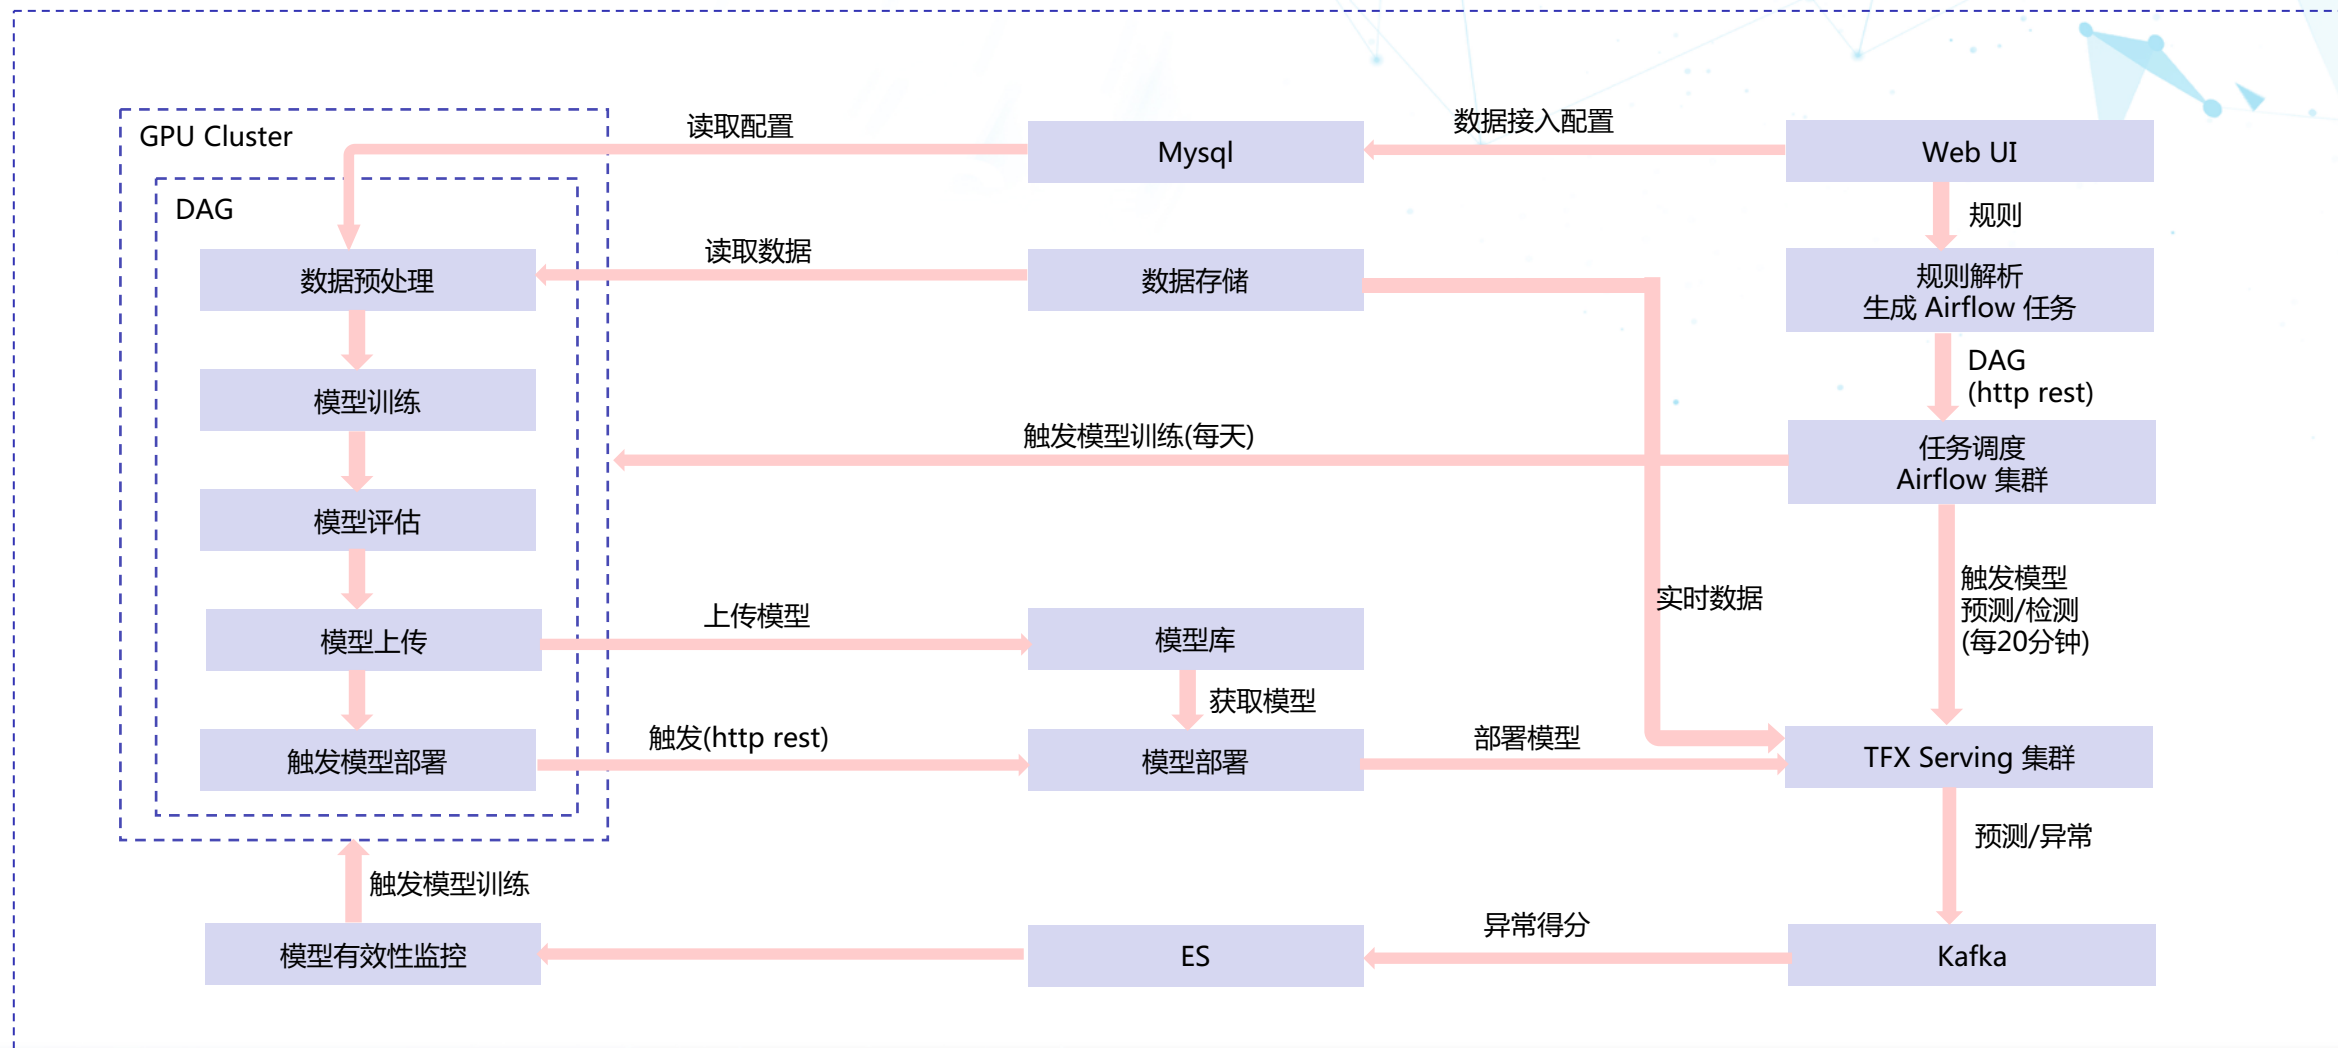
数据延时分析

描述性统计分析

- 数据源多样化：支持kafka、clickhouse、VictoriaMetrics(Prometheus家族)等多种数据源的接入
- 数据聚合：可以根据指定的维度和指标对数据进行聚合
- 数据衍生：支持根据不同的指标进行运算，从而得到用户想要的复合数据
- 关键性能指标：目前上限tps为5.8w/s，最高可支持50w/s
- 分布式存储处理：支持数据异步写入处理。目前使用clickhouse集群作为存储介质，使用10台物理服务器进行分布式处理。
- 数据分析：从接入的数据量趋势、接入时间来分析数据的质量，做到从源头对数据进行监控

异常检测平台深度剖析

模型管道的构建



异常检测平台深度剖析


异常点检测

异常检测流程

1. 使用近400分钟的指标信息，通过构建的模型，预测未来30分钟每1分钟的预测值和概率分布函数。
2. 设置采样率，根据概率分布函数进行随机采样。
3. 定义异常百分率，使用采样后的数据计算自动获取异常上下边界。
4. 指标值与异常点上下边界进行匹配，判断该点是否为异常点。


异常检测结果

- 蓝色曲线为指标正常值，红色曲线为检测出来的异常值。
- 灰色阴影部分为异常上下边界阈值。



异常检测平台深度剖析

告警分析



登录成功数 异常

排序	errorCode	本期 ↑	对比期	增长率 ↑
1	error001	286	286	31.58%
2	error001	286	286	31.58%
3	error001	286	286	31.58%
4	error001	286	286	31.58%
5	error001	286	286	31.58%
6	error001	286	286	31.58%

共124条记录

本期均值 98.89万
同期均值 38.89万
同期增长率 +18.80% ↑
告警点本期值 18.80万
告警点同期值 38.89万
告警点同期增长率 +12.68% ↑

告警趋势分析:

1. 根据告警发生时间进行趋势分析
2. 统计期内指标对比分析, 结合业务知识判断告警的准确性
3. 对发生的告警进行标记, 为后续模型优化提供数据基础。

数据预处理

模型训练

在线预测

剔除异常点

异常标记存储



告警异常码分析:

1. 为用户提供异常码分析, 帮助用户可以快速判断告警的准确性。
2. 用户根据异常码, 可以定位异常明细, 全方位显示异常信息。。

异常检测平台深度剖析

根因分析

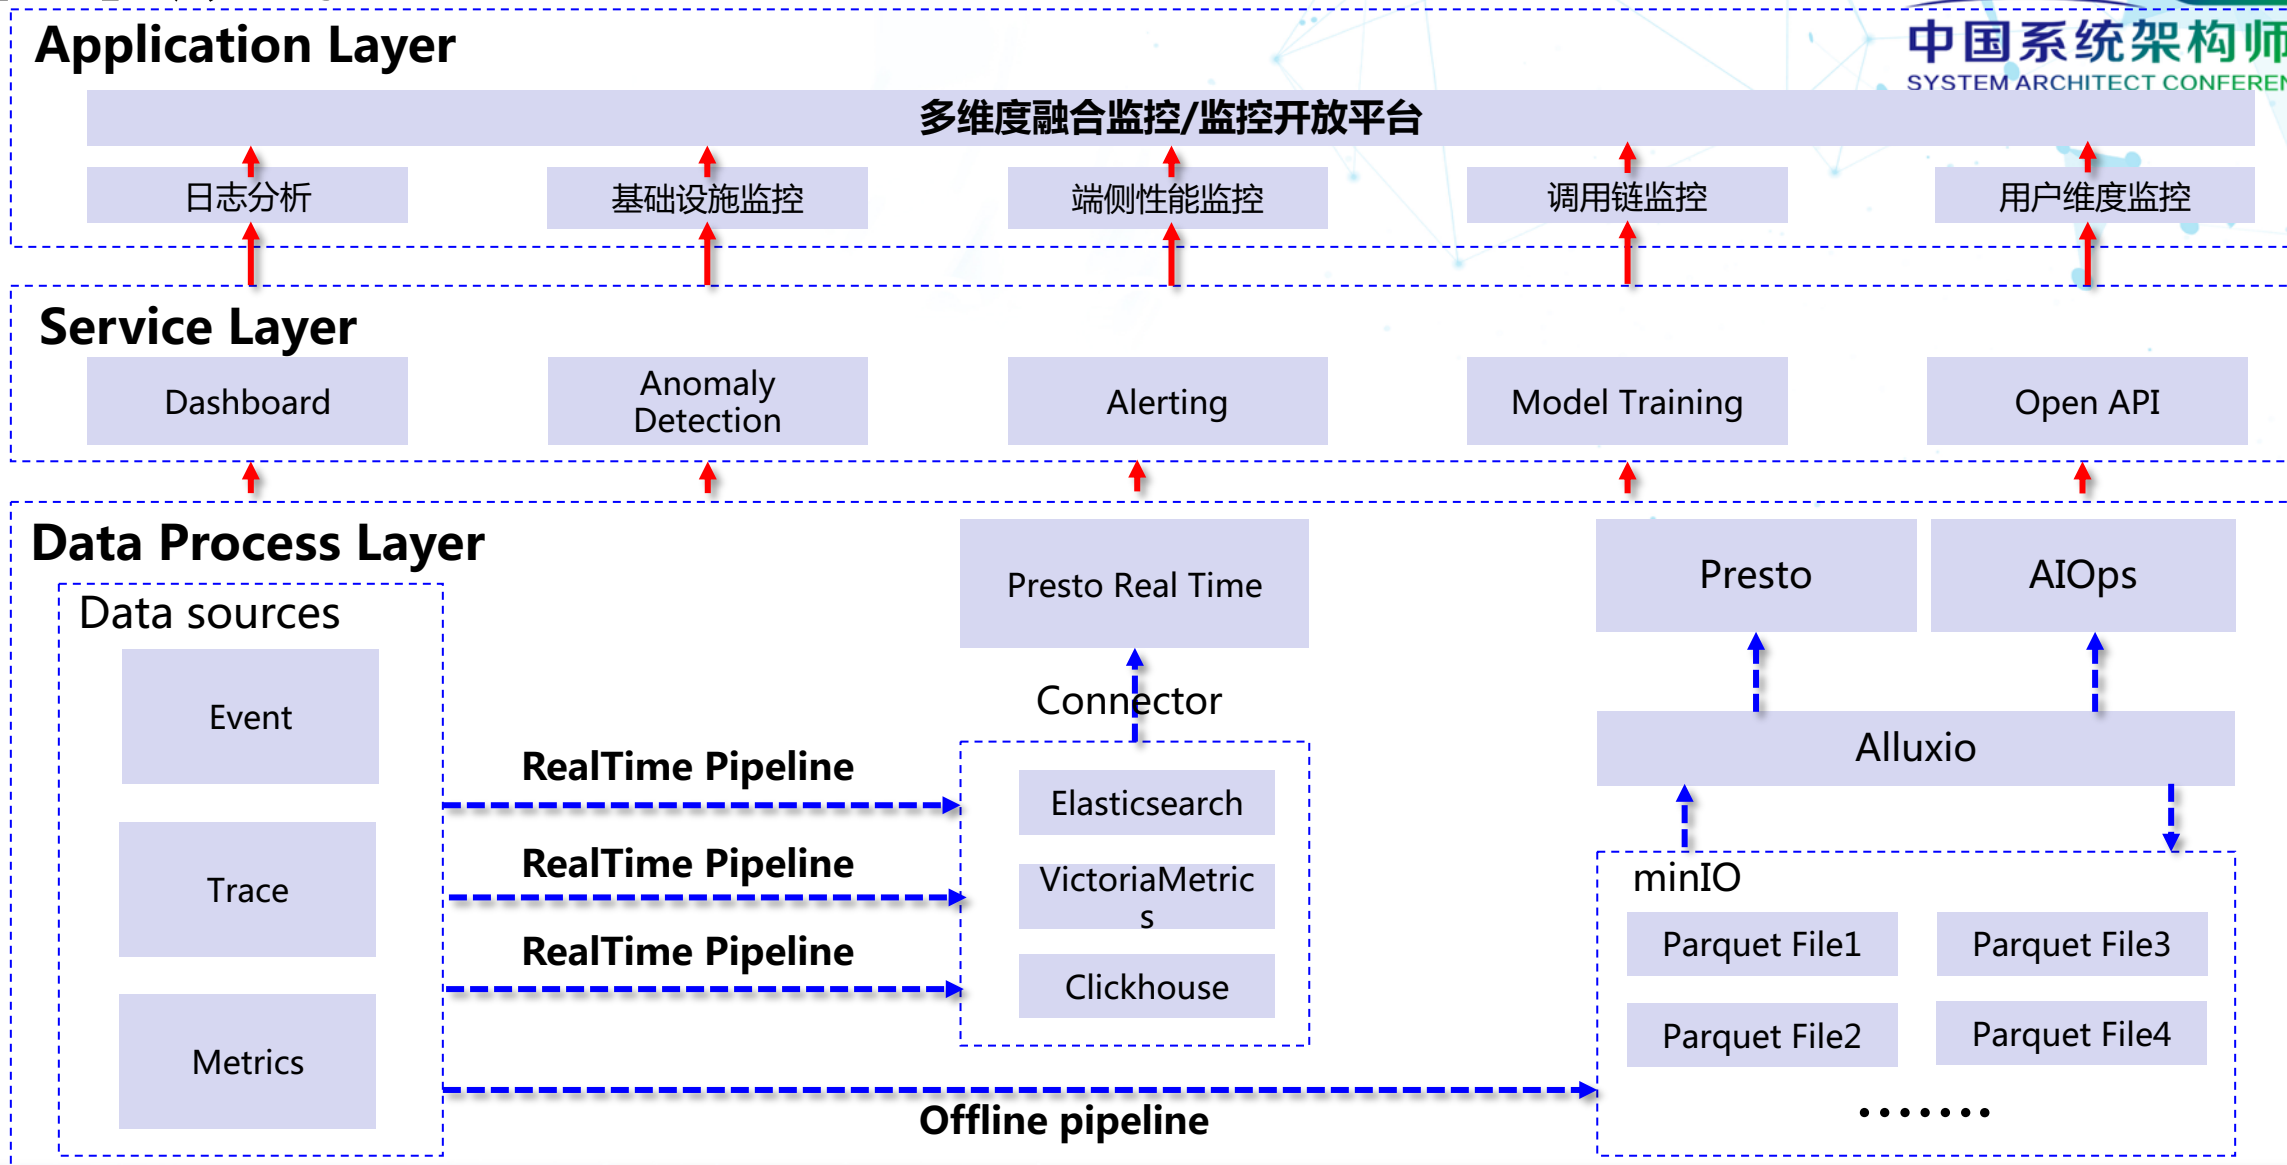
- 影响因素：以单维度指标为基础，使用 HotSpot 家族的算法对异常数据进行分析，定位出主要的影响因素，帮助用户快速定位异常数据维度，大大提高工作效率；
- 告警标记：用户在告警分析和处理中，根据最终的影响因素来对算法分析出的主因进行判断标记，后续算法根据标记信息进行算法调优，形成良性循环。



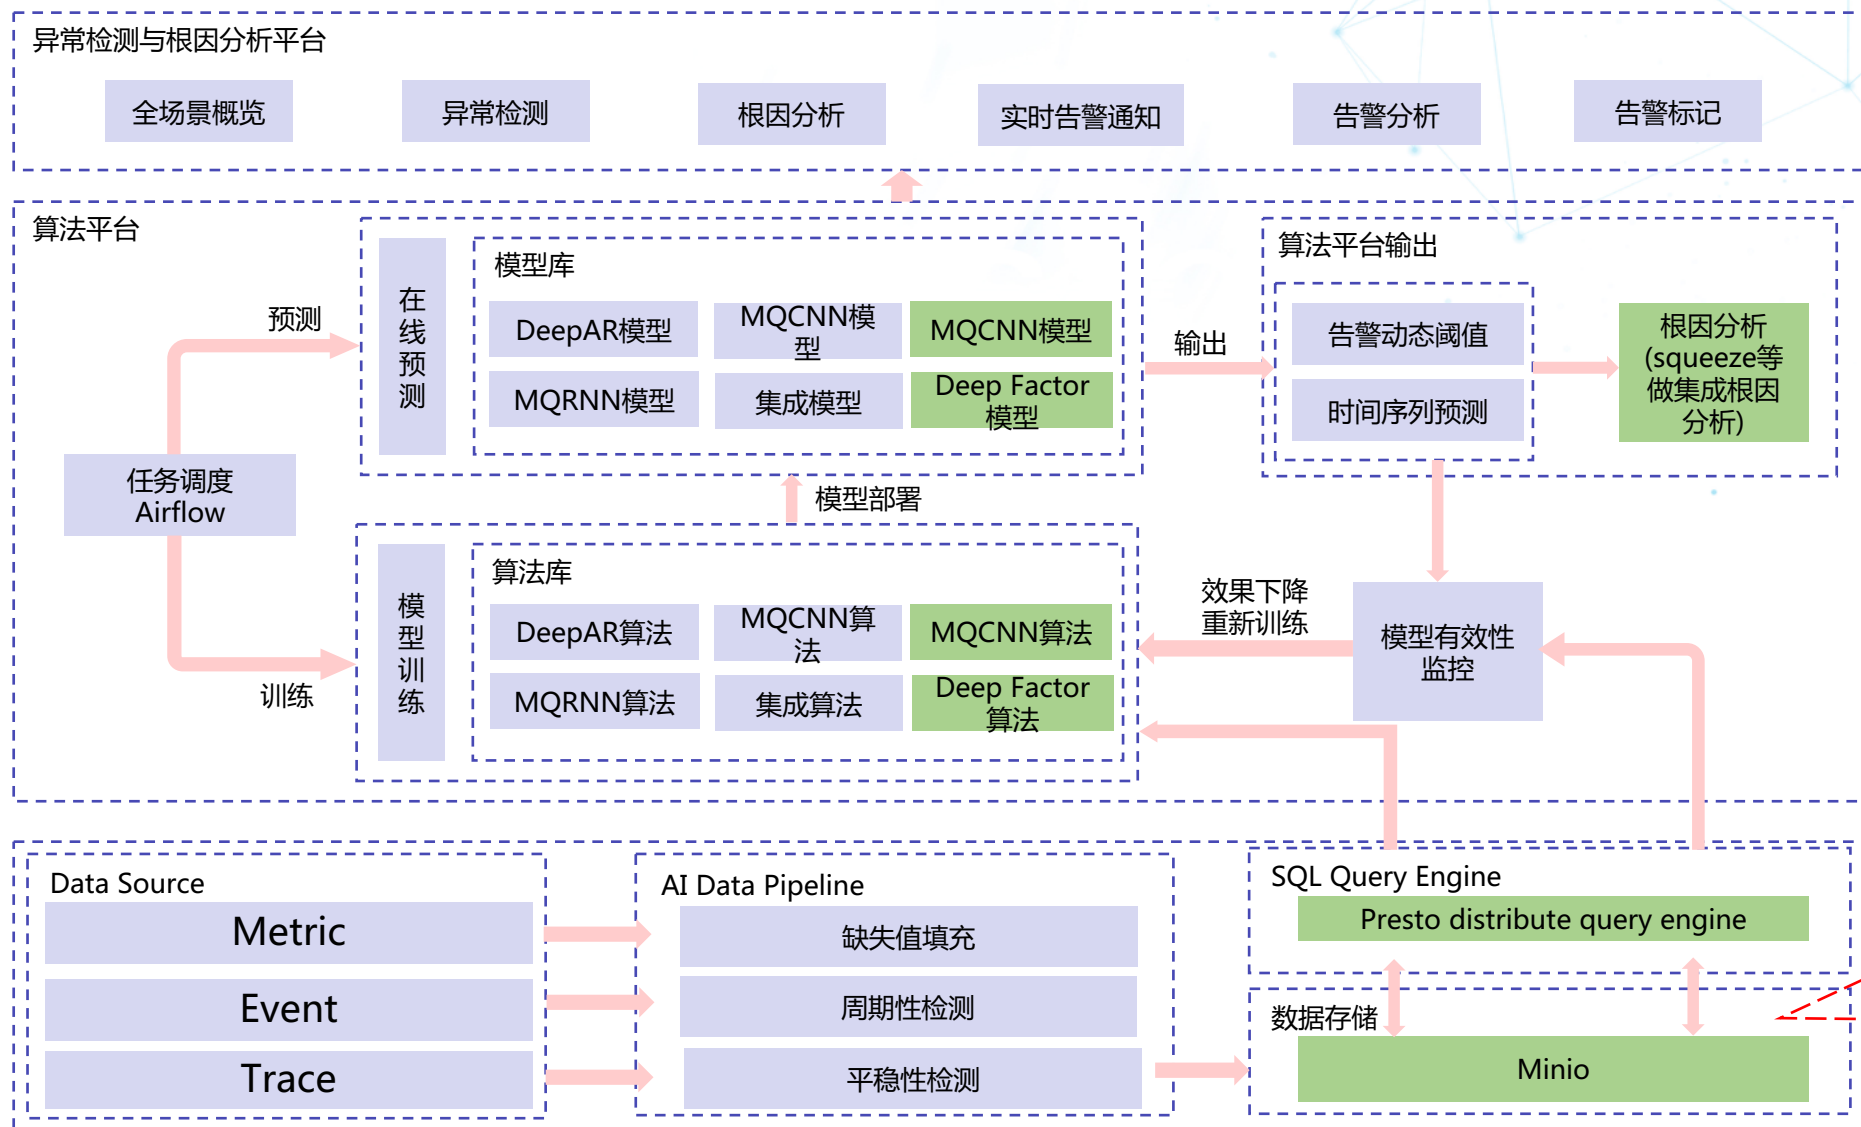
主要内容

- 背景介绍
- 大规模时间序列分析
- 根因定位
- 异常检测平台深度剖析
- 未来规划

未来规划



未来规划



- 自定义仪表盘异常点分析
- TF框架升级到2.0
- 研发类似AWS GluonTS的统一异常检测/根因定位的Library
- 异常检测算法继续拓展（深度状态空间，深度高斯过程）
- 根因定位算法拓展到图神经网络以及图顶点熵领域
- 使用AutoML技术，实现自动调参，模型架构自动搜索功能
- 预测结果以API/SDK方式提供给下游
- 使用MinIO实现统一存储，使用Presto统一分析引擎。



Thanks